



利用机器学习和特征选择对天气预报的后处理进行改进与优化

Kazuma Iwase, Tomoyuki Takenawa*

海洋科学 研究科

与技术学院, 东京 海洋 大学 海洋科学 与 技术

, 日本

ARTICLE INFO

数据集 链接:

<https://github.com/takenawa/PostMSM>

关键词: 天气 预
测 后处理 机器 学
习 特征 选择

ABSTRACT

本研究旨在开发并改进基于机器学习的后处理模型, 用于降水、温度和风速预测, 使用日本气象厅提供的日本18个地点(包括平原、山地地区和岛屿)的中尺度模式数据集。通过将目标地点周围格点的气象变量作为输入特征, 并基于相关分析进行特征选择, 我们发现, 在我们的实验设置中, 基于LightGBM的模型比本研究中测试的特定神经网络基线(包括复现的CNN基线)实现了更低的均方根误差, 并且在许多地点和预报时效上, 通常也比原始MSM预报和JMA后处理产品MSM指导产品取得了更低的均方根误差。由于降水分布高度偏斜且包含大量零值, 我们还额外研究了基于Tweedie的损失函数和事件加权训练策略用于降水预报。这些方法相对于原始LightGBM模型提高了事件导向的性能, 尤其是在较高降雨阈值下, 尽管增益因地点而异, 且整体性能仍略低于MSM指导产品。

1. 引言

1.1. 研究背景与目标

数值天气预报(NWP)是一种基于观测数据, 利用数学模型表示未来大气状态的主要天气预报方法。多年来, 它通过在物理过程描述、模式初始化(包括同化)以及引入集合建模方面的进步而不断发展(Bauer等, 2015)。然而, 数值天气预报并非没有局限性, 例如预报误差和偏差。尽管预报方差可能无法避免, 但已经开发了几种使用机器学习模型的后处理技术来减轻这些偏差(Liu等, 2023; Rojas-Campos等, 2023; Yoshikane和Yoshimura, 2022; Zhang和Ye, 2021; Kudo, 2022; Peng等, 2020; Tang等, 2021; Salazar等, 2022; Xu等, 2020)。

日本气象厅还引入了一种名为MSM指导产品(MSMG)的后处理方法, 用以修正中尺度模式(MSM)的误差。与全球模式相比, MSM具有更精细的网格间距(5公里), 并覆盖日本周边地区(JMA, 2024)。在MSMG中, 日本气象厅主要采用统计方法, 如卡尔曼滤波、频率偏差修正和神经网络, 以减少MSM中的系统性偏差。

本研究旨在利用机器学习开发后处理模型, 针对降水、温度和风速——这三种代表性的气象变量——使用MSM数据对日本全境18个地点(包括平原、山地地区和岛屿)进行预测。预测地点周围格点的气象变量被用作输入特征, 并应用了基于相关分析的特征选择。在我们的实验设置中, 基于LightGBM的模型比测试的神经网络基线(包括复现的CNN基线)实现了更低的均方根误差, 并且通常也比原始MSM预报和日本气象厅后处理产品MSM指导产品(MSMG)实现了更低的均方根误差。在基于LightGBM的模型中, 使用周围网格信息并采用基于相关特征选择的模型在多个地点和预报时效中显示出最低的均方根误差。

对于降水, 我们进一步检验了基于Tweedie的损失函数和事件加权训练策略, 这些策略在RMSE提升有限的情况下, 仍改善了某些站点和降雨阈值的事件导向指标。

1.2. 相关工作

多项研究已开发出后处理模型用于降水预测, 采用诸如卷积神经网络(CNN)等方法,

* 通讯作者。邮箱地址: takenawa@kaiyodai.ac.jp (T. Takenawa)。

神经网络和支持向量机(Zhang and Ye, 2021; Liu等人, 2023; Rojas-Campos 等人, 2023; Yoshikane和Yoshimura, 2022)。其中, Zhang and Ye (2021) 对降水预测的机器学习模型、输入参数和训练数据周期进行了对比实验, 并得出结论: LightGBM在测试的模型中提供了最均衡的性能。

对于温度后处理模型, 已采用CNN、神经网络和LightGBM (Kudo, 2022; Peng等, 2020; Tang等, 2021)。Kudo (2022) 开发了一个基于CNN的温度后处理模型, 针对日本关东地区, 并证明其性能优于日本气象厅的MSMG。

风速后处理模型也通过神经网络和LightGBM进行了探索 (Salazar 等, 2022; Tang等, 2021; Xu等, 2020)。Xu等 (2020) 利用LightGBM进行风速预测, 分析了从模型中得到的特征重要性。他们的研究表明, 使用包括各种气象要素在内的全部数据作为输入, 其性能优于特征主要限于风速的模型。

除了使用NWP输出, 一些研究还利用了来自现有天气预报服务的气象预报数据 (Iwase and Takenawa, 2024; Tsipis等, 2023)。Iwase and Takenawa (2024) 采用机器学习模型, 如LightGBM、XGBoost和神经网络, 预测山区的温度和降水。通过将周边天气预报数据作为输入变量, 其结果优于现有的天气预报服务。

在最近的机器学习研究中, 深度学习方法在自然语言处理和图像识别等领域取得了显著发展。相比之下, 对于表格数据, 基于树的模型目前在准确性上优于深度学习模型, 并且需要更少的超参数调整成本 (Shwartz-Ziv and Armon, 2022; Grinsztajn 等人, 2022)。树基模型在处理通常涉及表格数据的数值天气预报后处理中也被证明是有用的 (Zhang and Ye, 2021; Xu 等人, 2020)。最近, Hietala and Partio (2025) 报告说, 基于树的梯度提升后处理方案 (XGBoost) 降低了短程近地面预报的均方根误差。

本文的其余部分结构如下。第2节定义了本研究所用的方法和数据。第3节展示结果与讨论。最后, 第4节总结本研究。

2. 方法

2.1. 数据

在本研究中, 我们使用日本气象厅的MSM数据作为模型输入, 并将观测数据作为训练的目标数据。MSM数据由京都大学可持续人类圈研究所 (RISH, 2024) 收集和分发。日本气象厅的观测数据包括过去三小时的累积降水量、每小时温度以及风速。我们选择了日本全国18个观测站点 (图1, 表1)。此外, 为了比较预报结果, 我们还收集了日本气象厅提供并由日本气象业务支援中心 (JMBSC) 分发的后处理预报MSMG数据。

MSM 包含未来大气状况的三维网格预测, 包括温度、风速、湿度和太阳辐射, 网格间距精细约为 5 公里。预报覆盖日本及周边海域 (JMA, 2024)。地面数据每小时提供一次, 而气压层数据每三小时提供一次。预报每三小时发布一次 (00、03、06、09、12、15、18、21 UTC), 最长可预测 39 小时。地面网格包含 505×481 个点 (网格间距: 0.05° 纬度 $\times$ 0.0625° 经度), 而气压层网格包含 253×241 个点 (网格间距: 0.1° 纬度 $\times$ 0.125° 经度)。

表 1 图1中显示18个站点的纬度、经度、海拔、和 站点 编号 的 18 个 站点 如 图 1 所示。

	纬度	经度	海拔	站点 编号
Ashimine	26.193	127.638	3	0
Uchinoura	31.277	131.055	8	1
Minamiaso	32.832	131.013	394	2
Uwano kogen	35.432	134.583	540	3
今治	34.053	132.975	27	4
堺	34.555	135.485	20	5
桑名	35.050	136.693	3	6
Sekigahara	35.363	136.467	130	7
Itoigawa	37.043	137.875	8	8
Nob 惠山	35.948	138.472	1350	9
Niijima	34.368	139.268	29	10
辻堂	35.320	139.450	5	11
Saitama	35.875	139.587	8	12
Kusatsu	36.617	138.592	1223	13
釜石市	39.270	141.878	5	14
Oma	41.527	140.912	14	15
Ishikari	43.193	141.370	5	16
Kamikawa	43.847	142.753	324	17

表2 用作预测因子的气象要素, 包括名称和单位。✓表示该要素在地面和/或代表气压层 (850、500和200百帕) 上使用。(相对湿度仅在850/500百帕层使用。)

元素 名称	地面 (每小时)	气压 层 (每 3 小时)	Unit
温度	✓	✓	°C
相对湿度	✓	850/500 百帕 仅	%
逐时降水	✓		mm
风速 速度	✓	✓	m s^{-1}
U 风分量	✓	✓	m s^{-1}
V 风速 分量	✓	✓	m s^{-1}
垂直 速度		✓	hPa s^{-1}
地面 气压	✓		hPa
海平面 气压	✓		hPa
位势 高度		✓	m
太阳 辐射	✓		W m^{-2}
总云 量	✓		%
低云 量	✓		%
中云 量	✓		%
高云 量	✓		%

覆盖 从 西北角 (47.6° N , 120° E) 到 东南角 (22.4° N , 150° E) 的区域。

MSM在地面和多个标准气压层上输出多种气象要素。在本研究中, 我们使用表2列出的要素作为预测因子。对于气压层变量, 尽管MSM在更多气压层上提供输出, 但我们仅使用三个代表性层次 (850百帕、500百帕和200百帕), 遵循先前的工作 (Liu等, 2023), 以捕获低层、中层和高层大气的信息, 同时降低维度。CNN基线使用了不同的输入配置, 遵循先前的工作 (包括额外的近地面气压层); 详见第2.5节。

对于每个站点, 我们训练一个独立的回归模型。除基于CNN的模型外, LightGBM和神经网络的输入是通过拼接以下内容构建的一维特征向量: (i) 时间窗口 $(t, t - 1, t - 2)$ 内的地表变量, (ii) 目标时刻 t 仅有的气压层变量 (850百帕、500百帕和200百帕), 以及 (iii) 辅助标量特征 (提前时间、月和小时)。所有网格化预测因子在拼接前都被展平。时间窗口长度选择为与MSM/MSMG的3小时一次预报周期匹配, 以便在超前时间和预报周期内获得一致的预测因子集。

输入 变量 包括 13个 地面 变量 和 7个 气压层 变量, 如 表 2所示。在这些 气压层 变量中, 相对 湿度 仅 在 两个 层次 (850 和




图 1. 展示 18 个选定地点的地图。

500

我们准备了两种输入配置。在第一种配置中，仅使用距离预测点最近的网格单元。在这种配置下，输入特征的总数为 62，计算方式为

$$13 \times 3 + (6 \times 3 + 2) + 3 = 62,$$

其中 13×3 代表三个时间步的 13 个地表变量， $(6 \times 3 + 2)$ 统计 t 时刻的气压层组合（六个变量在三个层次加上两个层次的相对湿度），+3 代表提前时间、月和小时。

在第二种配置中，包含周围的网格单元以评估空间上下文的好处。由于气压层场的水平网格间距是地表场的两倍，我们对地表变量使用 11×11 网格，对气压层变量使用 7×7 网格，以便覆盖区域相当。在这种周围网格配置下，输入特征总数为 5702，计算方式为

$$13 \times 3 \times 11 \times 11 + (6 \times 3 + 2) \times 7 \times 7 + 3 = 5702,$$

其中 13 是地表变量的数量，3 是地表变量的时间步数， 11×11 是地表网格， $(6 \times 3 + 2)$ 统计时间 t 上的气压层组合， 7×7 是气压层网格，+3 代表提前时间、月和小时。

输出变量是过去三小时的累积降水量，以及每小时的温度和风速。观测

数据来自 2019 年至 2021 年用于训练，2022 年用于验证，2023 年用于测试，如表 3 所示。由于 MSM 提供完整字段且无缺失值，仅从数据集中排除包含缺失值的观测样本。验证数据仅用于模型选择和超参数调整，在测试前未用于重新训练模型。图 2 展示了每个地点和气象变量的箱线图。

对于 MSMG，过去三小时的累积地表降水量以及每小时的地表温度和风速，可提前 39 小时进行预测，预报输出每三小时一次（00、03、06、09、12、15、18 和 21 UTC）。降水预报在维度为 560 （经度） $\times 480$ （纬度）的网格上提供，对应的网格间距为纬度 0.05° 、经度 0.0625° ，覆盖范围为西北方向（ 47.975°N , 120.03125°E ）至东南方向（ 20.025°N , 149.96875°E ）。相比之下，温度和风速的预报则在 JMA 观测站的地点提供。

数据集总结如下。输出包含三个变量（降水、温度和风速），而输入在各变量中相同。缺失值仅出现在观测数据中。时间范围涵盖整个训练集（2019–2021）、验证集（2022 年）和测试集（2023 年）。总行数由时段、预报周期、超前时间和地点的组合决定，而列数则根据输入配置有所不同。

表3 使用预测点周围网格时训练、验证和测试数据集中的样本数量，以及特征总数，以及基于相关分析进行特征选择后的特征数量。

	训练 样本	验证 样本	测试 样本	原始 特征	丢弃的 特征
Ashimine	113 854	37 882	37 934	5702	239
Uchinoura	113 854	37 843	37 947	5702	296
Minamiaso	113 828	37 830	37 960	5702	502
Uwanokogen	108 642	37 570	37 947	5702	385
今治	113 802	37 830	37 934	5702	408
堺	113 776	37 830	37 947	5702	455
桑名	111 891	37 817	37 960	5702	354
Sekigahara I	113 568	37 830	37 934	5702	437
toi川 N	113 609	37 843	37 817	5702	516
ob新岛惠	113 022	37 544	37 791	5702	869
山	113 477	37 778	37 921	5702	236
Tsujido	113 763	37 791	37 960	5702	416
Saitama	113 789	37 817	37 960	5702	248
Kusatsu	112 359	37 271	37 752	5702	733
金石市	113 464	37 687	37 921	5702	295
Oma	113 815	37 804	37 895	5702	256
石狩	113 243	37 791	37 934	5702	271
Kamikawa	113 607	36 907	37 791	5702	413

时期: 2019–2023 (1826 天)

预报 周期 每日 : 8 (3小时一次)

每次循环的 预测 提前 时间: 13 (3–39 小时)

地点: 18

总 行数: 3,418,272 (移除 缺失 观测值 前)

2.2. LightGBM

先前关于表格数据和后处理模型开发的几项研究表明，基于决策树的模型在训练成本和性能评分方面优于其他机器学习模型。在基于决策树的模型中，LightGBM (Ke等, 2017) 尤其快速且高性能 (Iwase and Takenawa, 2024)。因此，本研究采用LightGBM来开发后处理模型。LightGBM是一种基于决策树的集成模型，采用顺序添加决策树并使用二次优化方法的提升算法。

由于LightGBM无法同时处理多输出变量，因此需要为每个输出变量单独创建模型。训练过程中，使用验证数据应用早停，耐心值为10个周期，损失函数设置为均方误差(MSE)。

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2$$

(1)

其中 N 是数据点的数量， $\hat{y}_i$ 是预测值，而 y_i 是观测值。

2.3. 特征 选择

当包含周围网格时，特征数量达到5702，这对LightGBM来说过于庞大。特征选择对于减少训练时间和防止过拟合是必要的。为此，采用了Bedi和Toshniwal (2018)中提出的相关分析方法（此后记为FS0）。FS0计算候选特征之间的成对绝对皮尔逊相关性，并去除冗余。

为避免删除关键输入信息，我们通过删除列将最接近预测目标的网格和日历变量从分析中排除。因此，相关分析仅在来自周围网格的特征之间进行。

让 τ 表示相关阈值。FS0 构建绝对相关矩阵 $|r(x_i, x_j)|_{i,j}$ 并按列顺序扫描特征在其列中。

对于每个特征 x_j ，如果存在任何较早的特征 x_i ($i < j$) 使得 $|r(x_i, x_j)| > \tau$ ，则删除 x_j （从左到右规则）。基于验证数据，阈值设置为 $\tau = 0.9$ 。每个位置经过相关分析后的特征数量汇总于表3。

在应用上述特征选择过程后，或在仅使用单网格数据的情况下，采用了以下三种进一步的特征选择方法来确定最优特征数量：

FS1. 一种基于每个特征与输出变量之间相关系数的方法。FS2. 一种基于每个特征与输出变量之间互信息的方法。FS3. 一种基于LightGBM计算的特征重要性的方法。


虽然存在许多特征选择方法，本研究采用了代表性方法 (Chandrashekar and Sahin, 2014; Ross, 2014)。基于相关系数的方法计算每个特征与输出变量之间的相关系数，并按相关系数降序选择特征。基于互信息的方法使用每个特征与输出变量之间的互信息，其中互信息衡量两个变量之间的依赖程度 (Ross, 2014)。基于LightGBM特征重要性的方法计算每个特征在LightGBM树分裂过程中对减少损失函数的贡献。此外，还对所选特征的数量进行了分析。无论特征选择结果如何，预测时间、月份和小时等变量始终包含在最终选择的特征中。

2.4. 参数 调优


参数调优使用Optuna (Akiba et al., 2019) 进行，Optuna是一个基于贝叶斯优化算法的参数优化库。具体而言，本研究采用LightGBMTuner (OPTUNA, 2024) 迭代计算每个参数的最优值。调优过程使用单个代表性地点进行，调优后的参数应用于其他地点。选定的代表性地点是关原，位于所有目标地点的中心附近。由于LightGBM无法处理多输出变量，因此针对每个输出变量分别进行调优。

2.5. 神经网络 和 CNN


为了与先前研究中使用的基于神经网络方法进行比较，我们还实现了一个前馈神经网络



(a) Precipitation



(b) Temperature



(c) Wind Speed

图 2. 各位置各气象变量分布的箱线图。对于降水，仅显示非零值（值 > 0 mm），以避免零降水的主导地位并提供信息丰富的可视化；降水轴以对数尺度显示。绿色三角形标记表示平均值。

和一个 CNN 模型。该神经网络的结构，使用 TensorFlow 和 keras.layers (TensorFlow, 2024) 实现，如下所示：

- 全连接层(1000, 激活=’ ReLU’)
- 全连接层(500, 激活=’ ReLU’)
- 全连接层(100, 激活=’ ReLU’)
- 全连接层(3)

输入 维度 对应于 经过 FS0 选择后的 特征 数量，输出 维度 (3) 对应于 降水、温度和 风速。

该 模型 使用 Adam 优化器（学习 率 0.001）（Kingma, 2014）进行 训练，以 均方误差 为 损失函数，并 以 均方根误差

（均方根误差）：

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2} \tag{2}$$

作为指标。训练 使用了 早停法，耐心 值为 10 轮次，基于 验证 均方根误差。我们 设置了 最大 1000 轮次，批量大小 为 64；实际 上，训练 通常 在 约 25–50 轮次 内 收敛，由于 早停法。

CNN模型有许多可能的变体，包括层数、卷积核大小、通道数、是否使用跳跃连接，以及优化和正则化方法的选择。对这些架构进行全面比较超出了本文的范围。因此，我们将比较范围限定在先前的使用CNN对 MSM数据进行后处理的工作基础上构建的CNN模型。




图 3. CNN 的架构。

对于CNN基线，我们遵循Kudo（2022年）的实验设置，在可比的数据条件下复现了一个具有代表性的基于CNN的先前方法。因此，与原始研究一样，CNN仅应用于温度预测。

我们的CNN使用单个预报时间空间场，没有回溯窗口。输入是一个以18个地点每个为中心的张量 $64 \times 64 \times 7$ 。七个通道包括四个地表场（地表温度、平均海平面气压和地表风速分量 U 和 V ）以及三个气压层（975、925和850百帕）的温度。由于气压层网格比地表网格更粗糙，气压层温度场首先在气压层网格上裁剪为 32×32 的块，然后上采样到 64×64 以匹配地表场。CNN的架构如图3所示，并在表4中总结。

归一化 对于 CNN 按照 以下 方式 进行：

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (3)$$

其中 x' 表示归一化值， x 是原始值， $x_{\min}$ 和 $x_{\max}$ 是MSM输入数据的最小值和最大值。这些最小值和最大值是针对每个预测时间（数据样本）计算的，而不是在整个训练数据集上计算。对于温度， $x_{\min}$ 调整为 $x_{\min} - 3$ ， $x_{\max}$ 调整为 $x_{\max} + 3$ 。在输出层之后应用逆归一化步骤，定义如下：

$$y' = y \cdot (x_{\max} - x_{\min}) + x_{\min} \quad (4)$$

其中 y 是输出层的输出， y' 是逆归一化后的值。引入这些归一化和逆归一化过程是为了尽可能复现先前的研究，因此应将其视为基线实现的一部分，而非本研究中独立优化的设计选择。

CNN 的学习设置，包括优化器、损失函数和批量大小，与 NN 相同。我们设置了最大 1000 个轮次；在实践中，训练通常会在约 15–20 个轮次内收敛，得益于早停。

2.6. 评估指标

除 RMSE 外，我们还使用了平均误差（ME），

$$ME = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i),$$

用于评估模型偏差，其中 N 是数据点数量， $\hat{y}_i$ 是预测值，而 y_i 是观测值。

此外，还使用了以下指标来进一步评估特定变量的模型性能。

表 4 摘要：每个 CNN 层的处理过程。每个层的实现使用 TensorFlow（TensorFlow，2024）keras.layers 进行描述。

层功能		
ZeroPadding2D(padding=(2, 2))		
卷积大小=5, 步长=1, 填充='valid')		
Conv1	2D最大池化(pool_size=2, 步长=2)	
	Batch归一化()	
	激活('ReLU')	
添加2D (填充=(2, 2))		2D卷积(64)
步长=1, 填充='valid')	ZeroP	
Conv2	2D最大池化(池大小=2, 步长=2)	批
	激活('relu')	
	全连接层(4096)	
FC1	批量归一化()	
	激活('relu')	
FC2	Dense(1)	

2.6.1. 温度和风速的统计检验 d

通过配对绝对误差进行了统计比较。让

$$e_i^{\text{main}} = |\hat{y}_i^{\text{main}} - y_i|, \quad e_i^{\text{base}} = |\hat{y}_i^{\text{base}} - y_i|$$

用 i 表示主模型和基线模型的绝对误差。然后定义平均绝对误差（平均绝对误差）为

$$MAE_{\text{main}} = \frac{1}{N} \sum_{i=1}^N e_i^{\text{main}}, \quad MAE_{\text{base}} = \frac{1}{N} \sum_{i=1}^N e_i^{\text{base}},$$

并将配对差异定义为

$$d_i = e_i^{\text{main}} - e_i^{\text{base}}.$$

基于这些配对差异，我们对温度和风速进行了配对 t -检验和威尔科克森符号秩检验。由于样本量非常大，这些检验仅作为补充信息解释，实际意义主要从误差指标本身评估。

2.6.2. 基于事件的降水指标

对于降水，预报技巧还额外使用基于事件的指标进行评估。对于每个降水阈值 τ ，预报和观测值被转换为二元事件。让 $H(\tau)$ 、 $M(\tau)$ 和 $F(\tau)$ 分别表示命中、漏报和虚警的数量，

在 阈值 τ 处。然后，基于事件的指标被定义为

$$\begin{aligned} \text{TS}(\tau) &= \frac{H(\tau)}{H(\tau) + M(\tau) + F(\tau)}, \\ \text{POD}(\tau) &= \frac{H(\tau)}{H(\tau) + M(\tau)}, \\ \text{FAR}(\tau) &= \frac{F(\tau)}{H(\tau) + F(\tau)}, \\ \text{Bias}(\tau) &= \frac{H(\tau) + F(\tau)}{H(\tau) + M(\tau)}. \end{aligned}$$

2.7. 加权 Tweedie 模型 用于 降水

降水是一个非负变量，具有高度偏斜的分布和许多零或接近零的值。在这种条件下，基于均方误差的标准回归训练往往被大量弱降水或无降水样本所主导，因此可能导致预测偏向于中间值，而无法充分提高中强度到强降水事件的预报精度。为了解决这些特征，在本研究中，我们检验了一种在LightGBM训练中使用Tweedie损失函数和样本权重系数进行降水预测的模型（以下简称加权Tweedie模型）（Jørgensen, 1997; Ke等, 2017; Dunn和Smyth, 2005）。在少数站点的初步实验中，加权Tweedie模型比仅使用加权或仅使用Tweedie损失的变体显示出更多的改进，因此我们在此重点关注这种变体。

令 $y_i \geq 0$ 表示样本 i 的观测降水，并令 $\mu_i > 0$ 表示预测的平均降水。Tweedie分布属于指数分散族，并满足（Jørgensen, 1997; Dunn和Smyth, 2005）

$$\text{Var}(Y_i) = \phi \mu_i^p,$$

其中 $\phi > 0$ 是分散参数而 p 是 Tweedie 方差幂。在本研究中，指数 p 被视为可调超参数。

样本权重被定义为观测降水的单调非减分段线性函数。令节点位置为

$$x_0 = 0, \quad x_1 = 5, \quad x_2 = 10, \quad x_3 = 15, \quad x_4 = 20 \text{ mm},$$

且对应的权重值为

$$w_0, w_1, w_2, w_3, w_4.$$

施加了单调性约束，

$$1 = w_0 \leq w_1 \leq w_2 \leq w_3 \leq w_4,$$

已施加。然后，通过相邻节点之间的线性插值，将样本权重函数 $w(y)$ 定义如下：

$$w(y) = \begin{cases} w_0 + \frac{w_1 - w_0}{x_1 - x_0}(y - x_0), & x_0 \leq y \leq x_1, \\ w_1 + \frac{w_2 - w_1}{x_2 - x_1}(y - x_1), & x_1 < y \leq x_2, \\ w_2 + \frac{w_3 - w_2}{x_3 - x_2}(y - x_2), & x_2 < y \leq x_3, \\ w_3 + \frac{w_4 - w_3}{x_4 - x_3}(y - x_3), & x_3 < y. \end{cases}$$

在实现中，生成的权重被裁剪到范围

$$1 \leq w(y) \leq w_{\max},$$

其中 $w_{\max} = 10$ 。因此，降水强度较高的样本对训练贡献更大，而单调性约束保持了加权方案的稳定性和可解释性。

使用这些权重，通过最小化加权 Tweedie 损失来训练降水模型。

$$\mathcal{L}_{\text{train}} = \sum_{i=1}^N w(y_i) \ell_{\text{Twe}}(y_i, \mu_i),$$

其中 $\ell_{\text{Twe}}(y_i, \mu_i)$ 表示样本 i 的 Tweedie 损失。本研究中，我们使用了 LightGBM（Ke等, 2017; LightGBM贡献者, 2026）实现的 Tweedie 目标函数。除下文描述的降水损失函数和样本加权方案外，输入数据配置和树相关 LightGBM 设置与“around all tune”模型保持一致。

虽然模型使用加权Tweedie损失进行训练，但超参数在Optuna中基于基于事件的评估分数进行选择，因为加权的目的是提高相关降水阈值下的性能。调优的超参数是Tweedie方差幂 p 以及决定权重函数形状的参数，并且由于加权Tweedie模型的行为表现出强烈的站点依赖性，因此对每个观测站点分别进行调优。对权重函数施加了单调非递减约束，以确保权重不会随着降水强度的增加而减少。

使用第 2.6.2 节定义的基于事件的指标，各阈值的 TS 值通过几何平均进行聚合：

$$S_{\text{geo}} = \exp\left(\frac{1}{|\mathcal{T}|} \sum_{\tau \in \mathcal{T}} \log(\max(\text{TS}(\tau), \epsilon))\right).$$

此外，为了抑制事件频率的高估或低估，对选定阈值的预报偏差施加了惩罚。通过这种方式，Optuna 中使用的总得分定义为

$$S_{\text{total}} = S_{\text{geo}} - \sum_{\tau \in \mathcal{T}_{\text{bias}}} \gamma_{\tau} \left| \log(\max(\text{Bias}(\tau), b_{\min})) \right|.$$

这里， $\gamma_{\tau} \geq 0$ 表示惩罚系数， $\mathcal{T}_{\text{bias}}$ 表示应用偏差惩罚的阈值集合， $b_{\min}$ 是为数值稳定性设置的一个小正常数。该目标函数旨在鼓励模型在多个阈值上具有平衡的检测技能，同时减少对事件频率的显著过度预测或欠预测。

在当前实现中，用于优化的阈值设置为

$$\mathcal{T} = \{1, 2, \dots, 20\} \text{ mm},$$

并且在几何平均中，所有阈值使用相等的权重。此外，偏差惩罚应用于1、5、10和15毫米，对这些阈值均采用 $\gamma_{\tau} = 0.05$ ，并设置 $\epsilon = 10^{-6}$ 和 $b_{\min} = 10^{-6}$ 以保证数值稳定性。得到的模型在后续章节中称为加权 Tweedie模型。

3. 结果与讨论

3.1. 模型比较

3.1.1. 均方根误差与平均误差

首先，表 5 和 6 展示了各模型的均方根误差和平均误差，以及 MSM 和 MSMG 在验证和测试数据集上的结果。

对于均方根误差，验证和测试数据集均显示使用LightGBM的模型优于MSM和MSMG。同样，神经网络和CNN模型的性能逊于使用LightGBM的模型。此外，结合周围网格数据（周围）的模型性能略优于仅使用最近网格（单网格模型）的模型。这表明利用周围网格的特征并通过特征选择进行缩减，可以纳入改善准确性的信息数据。基于相关分析的特征选择（FS0）对周围网格数据在大多数情况下取得了最佳结果。在第2.3节所述的三种特征选择方法（FS1-FS3）中，未观察到性能提升。对于FS1到FS3的特征数量，我们使用了在第3.2节中对每种特征选择方法和每个输出变量表现最佳的值。

表5 验证数据的均方根误差和平均误差。“单网格模型”表示仅使用一个网格数据的模型，“周围网格数据”表示使用周围网格数据，“神经网络”表示神经网络，“全部数据”表示三种特征选择方法（FS1 - FS3）之前的数据，“皮尔逊相关系数法”表示基于相关系数的方法（FS1），“互信息方法”表示互信息方法（FS2），“特征重要性”表示LightGBM的特征重要性方法（FS3），“参数调优”表示参数调优。平均值在预测时间和地点上计算。

	RMSE			ME		
	降水	气温	Wind	降水	气温	Wind
MSM	2.948	1.836	2.096	0.048	-0.405	0.753
n	2.555	1.472	1.167	-0.075	0.130	-0.013
1grid all	2.510	1.364	1.070	-0.007	0.084	-0.018
单网格模型 皮尔逊相关系数法	2.526	1.367	1.070	-0.003	0.085	-0.018
单网格模型 互信息法	2.535	1.420	1.070	-0.001	0.096	-0.016
1网格 gb m	2.518	1.363	1.073	-0.006	0.085	-0.018
周围网格数据 a ll	2.501	1.332	1.050	0.001	0.081	-0.025
d 皮尔逊相关系数法	2.496	1.344	1.053	0.006	0.082	-0.026
around	2.505	1.342	1.051	0.004	0.083	-0.026
周围网格数据 互信息法	2.502	1.333	1.051	-0.002	0.080	-0.027
周围网格数据 梯度提升模型	2.489	1.326	1.046	0.009	0.074	-0.023
周围网格数据 全部数据 参数调优						
CNN		1.487			0.086	

表 6 均方根误差 和 平均误差 对 测试 数据。

	RMSE			ME		
	降水	气温	Wind	降水	气温	Wind
MSM	2.759	1.811	1.999	0.085	-0.340	0.673
MSMG	2.726	1.394	1.237	0.107	0.014	0.159
单网格模型 神经网络	2.439	1.485	1.175	-0.064	0.143	-0.060
单网格模型 全部数据	2.387	1.368	1.075	0.020	0.110	-0.058
单网格模型 皮尔逊相关系数法	2.390	1.369	1.076	0.016	0.109	-0.058
1grid mi	2.409	1.428	1.075	0.028	0.117	-0.057
1网格 gb m	2.392	1.368	1.078	0.017	0.111	-0.058
周围网格数据 a ll	2.358	1.341	1.053	0.031	0.111	-0.062
d 皮尔逊相关系数法	2.374	1.349	1.056	0.030	0.124	-0.062
around	2.381	1.347	1.055	0.033	0.119	-0.061
周围 互信息法	2.361	1.341	1.052	0.028	0.112	-0.063
around gbm	2.344	1.335	1.052	0.033	0.106	-0.059
周围 全部数据 参数调优						
CNN		1.501			0.179	

对于 平均误差，使用 LightGBM 的 模型 倾向于 在 验证 和 测试 数据集中 减少 偏差。然而，对于 验证 数据集中的 降水，MSM 获得了 最佳 平均误差，而对于 测试 数据集中的 温度，MSMG 表现 最佳。

在本研究的后续预测中，我们使用了“around all tune”模型，该模型展现了最佳的整体性能；其中，“around”表示使用周围网格预测因子，“all”表示保留所有选定预测因子而不进一步减少，“tune”表示超参数优化。

图4显示了测试数据的预测结果与MSM、MSMG以及选定位置和预测时间观测值的对比。在Kamikawa的3小时降水和Itoigawa的18小时风速案例中，后处理模型修正了明显的大偏差。另一方面，对于Itoigawa的18小时温度，观察到了后处理模型的部分修正。

3.1.2. 统计 检验 与 基于事件的 指标

对于温度和风速，表7总结了配对t检验和威尔科克森符号秩检验的结果，这些结果比较了主模型（around all tune）与基线模型（MSM和MSMG），基于第 2 6 1 MAE_{main} 节定义的指标。表格报告了配对差异标准差以及相应的单侧p值。由于样本量非常大，这些检验结果只能作为补充信息来解释，实际意义主要应从误差指标本身来评估。

对于 降水，表 8 总结 了 基于事件 的 指标，这些指标定义 于 第 2.6.2 节—TS、POD、FAR、和 Bias—针对 四个 降水

表7 成对t检验和威尔科克森符号秩检验结果，比较LightGBM “around all tune”模型（主模型）与温度及风速的基线模型。表格报告了主模型和基线模型的平均绝对误差、绝对误差配对差异的标准差（SD_{diff}）以及相应的单侧p值。所有检验均在N = 682个（305个配对样本）上进行。

变量	Baseline	MAE _{main}	MAE _{base}	标准差 ^{sd}	p _t	p _w
T温度	MSM	0.9888	1.3964	1.0840	0.000	0.000
Temp温度	MSMG	0.9888	1.0275	0.7675	0.000	0.000
风速	MSM	0.7549	1.4186	1.3530	0.000	0.000
风速	MSMG	0.7549	0.9035	0.6980	0.000	0.000

表格 8

降水的基于事件验证指标，汇总所有地点和预报时效。较高的TS和POD表示更好的检测技能，较低FAR表示较少的虚警，偏差值越接近1表示频率匹配越好。其中，“around all tune”表示原始的基于LightGBM的后处理模型。


阈值(mm)	Model	TS	POD	FAR	Bias
1.0	MSM	0.4311	0.6373	0.4287	1.1156
1.0	MSMG	0.4555	0.6558	0.4014	1.0956
1.0	周围网格数据 全部数据 参数调优	0.4293	0.6931	0.4699	1.3075
1.0	加权Tweedie	0.4435	0.7005	0.4527	1.2800
5.0	MSM	0.3226	0.5061	0.5293	1.0753
5.0	MSMG	0.3344	0.5014	0.4991	1.0009
5.0	周围网格数据 全部数据 参数调优	0.3059	0.3943	0.4228	0.6831
5.0	加权 Tweedie	0.3316	0.5208	0.5228	1.0912
10.0	MSM	0.2450	0.4084	0.6201	1.0749
10.0	MSMG	0.2485	0.4122	0.6152	1.0713
10.0	周围网格数据 全部数据 参数调优	0.1966	0.2356	0.4571	0.4340
10.0	加权 Tweedie	0.2520	0.3979	0.5927	0.9771
15.0	MSM	0.1902	0.3189	0.6796	0.9956
15.0	MSMG	0.2096	0.3551	0.6616	1.0492
15.0	周围网格数据 全部数据 参数调优	0.1251	0.1420	0.4877	0.2772
15.0	加权 Tweedie	0.1883	0.2719	0.6201	0.7158

阈值。这里，“周围 全部数据 参数调优”表示 我们的 原始 基于 LightGBM 的后处理 模型，而“加权 Tweedie”表示 加权 Tweedie 模型。


总体而言，MSMG在对比模型中表现良好。‘around all tune’模型在1.0毫米阈值下达到了最高的POD，表明对弱降水事件具有高灵敏度。然而，其FAR和偏差也是最大的，表明它倾向于过度预测降水发生。在5.0毫米及以上阈值，其TS和POD低于MSM和MSMG，偏差在10.0毫米和15.0毫米处远低于1，表明对较强降水事件的检测不足。相比之下，加权Tweedie模型在10.0毫米处改善了TS和偏差，并在5.0毫米处提高了POD。尽管其整体性能仍略低于MSMG，但在不同降水阈值间表现出了更好的平衡。

3.2. 特征选择 方法 的 比较


在此，我们于关原的一个地点进行了实验（类似于参数调优），以评估第2.3节提出的三种特征选择方法（FS1 - FS3）中选定特征数量的影响。对于仅使用最接近预测点的网格数据（单网格模型）以及包含周围网格数据（全部数据）的两种情况，分别应用了三种特征选择方法，并通过逐步增加选定特征数量（每次增加10个）来构建模型。图5总结了针对每种特征数量的验证数据的均方根误差k。结果表明，随着特征数量增加，精度趋于提高，但当特征数量超过一定阈值后趋于稳定。这表明相关分析后进一步进行特征选择并不能提升精度。



(a) Accumulated precipitation for the 0–3 h forecast interval at Kamikawa



(b) 18-h lead temperature at Itoigawa



(c) 18-h lead wind speed at Itoigawa

图4. 二月测试数据的预测结果示例，与MSM、MSMG及观测值对比。图(a)显示0-3小时预报时段的累积降水量，图(b)和(c)分别显示18小时预报时效的温度和风速。

3.3. 按 地点 和 预测 时间 的结果

3.3.1. 基于地点 的结果

图6总结了每个观测站点的测试数据的均方根误差。我们的后处理模型始终优于MSM，并且在大多数地点与MSMG表现相当或略优。对于降水，日本西南部（包括Ashimine和Uchinoura）的均方根误差值相对较大。这可能与这些地区频繁发生台风和强对流降水事件有关。相比之下，在Kusatsu和Nobeyama等内陆和山区，降水均方根误差值最低。

对于风速，MSM在岛屿和沿海地区（如Niijima和Oma）出现了极高的均方根误差。我们的模型显著降低了这些误差，使均方根误差达到与其他地区相当的水平。总体而言，均方根误差降低的区域模式表明，后处理模型有效减小了与地形及周围气象条件空间相关的偏差和噪声。

如表9所示，周围网格数据_全部数据_参数调优模型在所有地形类型和变量中取得了最低的均方根误差。改善在山地和岛屿地区最为显著，这些地区的空间

表9 按地形类别和模型划分的平均均方根误差。三个地形类别定义如下：山地（Kusatsu, Kamikawa, Nobeyama, Uwanoko- gen, Minamiaso）、岛屿（Ashimine, Niijima）和沿海/平原（Ishikari, Oma, Imabari, Kamaishi, Tsujido, Itoigawa, Uchinoura, Sekigahara, Saitama, Kuwana, Sakai）。

区域	周围_全部数据_参数调优			MSM			MSMG		
	降水	气温	风速	降水	气温	风速	降水	气温	风速
沿海/平原	1.982	1.343	1.002	2.454	1.793	1.864	2.400	1.363	1.211
岛屿	2.951	1.003	1.576	3.492	1.654	2.550	3.349	1.106	1.647
山地	2.369	1.398	0.822	2.630	1.804	1.337	2.605	1.508	1.038

气象条件的异质性 较大。这 表明， 融入 来自 周围 网格 的 空间 上下文 信息 可 提升 模型 在 复杂 地形 和 海岸 影响 下的鲁棒性。

3.3.2. 基于预测时间的结果

图7总结了每个预测时间在测试数据上的均方根误差。在均方根误差方面，选定的周围_全部_参数调优模型在几乎所有预报时效中都优于MSM和MSMG。对于所有方法，均方根误差随着预测时间变长而增加，这是常见的




图 5. 基于 所选特征数量 的 准确率 变化， 针对 特征选择方法 在 验证数据 上 于 Sekigahara 的 结果。 结果 在 预测时间 上 取平均。

数值天气预报(NWP)模型的特征，即预报精度随提前时间下降。在后处理结果中也观察到了类似的趋势，表明随着预报不确定性累积，基础 NWP 的残差会传播到修正后的预测中。尽管如此，选定的周围全部参数调优模型在所有预报时效中均保持比MSM更低的均方根误差，并且在许多情况下低于MSMG，证实了其随时间推移的稳定性。

3.3.3. 与观测值的散点图

图 8 比较了测试期间Sekigahara的观测值与模型输出。为了可读性，所有预测时间被合并，并随机选取了150个样本进行绘图。

3.4. 加权Tweedie模型的站点依赖行为

加权 Tweedie 模型 的效果 具有 强烈 的 站点 依赖性 。为了说明 这 一点 ，我们 比较 两个 具有 代表性 的 例子：

表 10 两个代表性案例的站点降水验证指标。较高的TS 和POD 表示更好的检测能力，而偏差值越接近1表示频率匹配越好。

Site	Model	阈值 (mm)	TS	POD	Bias
Kamikawa	MSMG	1.0	0.3802	0.5501	0.9933
	周围网格数据 全部数据 参数 调优	1.0	0.3817	0.5311	0.9367
	加权 Tweedie	1.0	0.3863	0.5319	0.9276
	MSMG	5.0	0.2447	0.3897	0.9464
	周围网格数据 全部数据 参数 调优	5.0	0.1541	0.1852	0.3492
	加权 Tweedie	5.0	0.1264	0.1488	0.3057
	MSMG	10.0	0.1278	0.2802	0.9973
	周围网格数据 全部数据 参数 调优	10.0	0.0267	0.0275	0.0687
	加权 Tweedie	10.0	0.0471	0.0522	0.0962
	MSMG	15.0	0.0667	0.1703	0.9725
	周围网格数据 全部数据 参数 调优	15.0	0.0000	0.0000	0.0000
	加权 Tweedie	15.0	0.0055	0.0055	0.0055
Saitama	MSMG	1.0	0.4391	0.6383	1.0919
	周围网格数据 全部数据 参数 调优	1.0	0.4150	0.6911	1.3563
	加权 Tweedie	1.0	0.4330	0.7160	1.3696
	MSMG	5.0	0.3549	0.4994	0.9065
	周围网格数据 全部数据 参数 调优	5.0	0.2308	0.2521	0.3444
	加权 Tweedie	5.0	0.3429	0.4959	0.9420
	MSMG	10.0	0.1935	0.3231	0.9923
	周围网格数据 全部数据 参数 调优	10.0	0.1493	0.1538	0.1846
	加权 Tweedie	10.0	0.3395	0.4962	0.9577
	MSMG	15.0	0.2048	0.3675	1.1624
	周围网格数据 全部数据 参数 调优	15.0	0.0678	0.0684	0.0769
	加权 TwTweedie	15.0	0.2600	0.3333	0.6154

Kamikawa（改进 有限）和 Saitama 在 18小时 的 预报时效（该 处 加权 Tweedie 模型 在 时间序列 比较中 显示出 更明显 的 改进）。


图9(a)显示了Kamikawa地区0–3小时累积降水量。在这种情况下，加权Tweedie模型保持接近原始的“around all tune”模型，两个预测之间的差异在许多事件中很小。这种行为与表10总结的站点聚合验证结果一致。在Kamikawa，加权Tweedie模型仅在1.0毫米阈值处产生了微小变化，在5.0毫米处未改善临界成功指数，尽管在10.0和15.0毫米处临界成功指数和POD略有改善。但总体而言，加权Tweedie模型在该站点仍明显低于MSMG，表明修改不足以克服该站点降水预报的困难。

相比之下，图9(b)显示了埼玉县15–18小时累积降水量案例，其中加权Tweedie模型更明显地修改了预测峰值，并且在多个事件中比“around all tune”更紧密地跟踪观测到的降水。这种行为也反映在表10的站点聚合结果中。在埼玉县，加权Tweedie模型在所有四个阈值上改善了相对于“around all tune”的临界成功指数，并在5.0、10.0和15.0毫米处显著提高了POD，同时在5.0和10.0毫米处将偏差更接近于1。在15.0毫米处，加权Tweedie模型在比较模型中仍显示出最佳临界成功指数，尽管其偏差仍低于1。这些结果表明，加权Tweedie模型可以改善某些站点的事件导向行为，特别是当原始模型低估中等至强降雨时。


综合来看，这些例子表明加权Tweedie模型主要用作站点依赖调整，而不是作为原始LightGBM模型的统一优越替代方案。这一观察结果与第2.7节讨论的站点级超参数调整需求一致。

4. 结论


在本 研究 中，我们 开发 了 基于 机器学习 的 后处理 模型，用于 降水、温度、以及 风速 预测，使用 了 观测数据 和 MSM 数据，覆盖 了 日本 的 18个 地点，包括 平原，



(a) Precipitation



(b) Temperature




(c) Wind Speed

图 6. 均方根误差 按 位置 在 测试 数据上。 结果 是 平均 在 预测 时刻上。


山地 地区, 以及 岛屿。 主要 研究结果 总结 如下 :

- 1. 使用周围网格数据结合基于相关性的特征选择, 相比仅使用单个最近网格, 提高了预测精度。这一结果支持了在通过特征选择控制特征维度的同时, 融入周围网格空间信息的有效性。相比之下, 在我们的实验中, 在此基于相关性的降维基础上进一步进行特征选择并未带来额外改进。
- 2. 在我们的 实验 设置 中, 基于LightGBM的 模型取得了 比 测试 的 神经网络 基线更低的 RMSE ,


- 包括复现的CNN基线在内, 并且通常也比JMA指导产品MSMG获得了更低的RMSE。然而, 由于神经网络比较仅限于特定的基线实现, 当前结果并不排除更强的深度学习架构可能表现更好。
- 3. 对于降水, 结果显示仅优化标准回归导向的目标并不一定足够, 特别是当预测目标是改善中等和强降雨事件的预测时。为解决此问题, 我们引入了基于Tweedie的损失函数和事件加权训练策略。这些方法改善了事件导向行为, 包括更好地检测较强降雨事件。



(a) Precipitation



(b) Temperature



(c) Wind Speed

图 7. 均方根误差 按 预测 时间 在 测试 数据上。结果 被平均 到 各地点。




图. 8. 在Sekigahara测试期间（所有提前时间合并）的散点图。 每个面板显示同一随机采样点的观测值与模型输出对比。




图9. 两个代表性案例的降水预报对比。图(a)为Kamikawa，加权Tweedie模型保持接近原始“around all tune”模型，改进有限。图(b)为Saitama，加权Tweedie模型在多次降水事件中显示出改进的事件导向行为。

在某些地点和阈值下。然而，改进并非在所有地点和条件下一致，表明仍需进一步改进。这种地点依赖性表明，与地形和站点特征（如纬度、经度和海拔）相关的站点间差异可能需要在未来工作中更明确地考虑。

为了补充主文中展示的代表性示例和汇总结果，附录中提供了按站点和预报提前时间划分的详细验证结果，包括降水预报的均方根误差（RMSE）和平均误差（ME），涉及MSM、MSMG和'around all tune'模型。

温度、风速以及基于降水的事件型指标（临界成功指数（TS）、探测概率（POD）、虚报率（FAR）和偏差（Bias）），包括加权Tweedie模型的结果。

CRediT 作者署名 贡献 声明

Kazuma Iwase: 写作 – 原始草稿，方法论，数据策管，概念化。
Tomoyuki Takenawa: 写作 – 审阅与编辑，写作 – 原始草稿，监督，资源，项目管理，方法论，概念化。

声明 生成式 AI 与 AI辅助 技术 在 稿件 准备 流程 中的 使用

在 本 手稿 的 准备 过程中， 作者 使用 了 Chat-GPT 来 辅助 代
码 编辑 和 语言 校对 。 所有 AI辅助 输出 均已 由 作者 根据 需要 进
行 了 审查 和 修改 ， 作者 对 手稿 的 内容 承担 全部 数据 责任 。

利益冲突声明 的 竞争性 声明

作者 声明 ： 他们 没有 已知 的 竞争性 财务 利益 或 个人 关系
可能 影响 本文 所 报告 的 工作 。

致谢

作者感谢审稿人的仔细阅读和宝贵意见。第一作者得到了东京海洋大
学海洋产业AI人才培养WISE项目的资助；第二作者得到了日本学术振兴
会[JSPS]，科研费（C）（22K03383）的资助。

附录 A. 补充 数据

补充 材料 与 本文 相关 的 补充 材料 可 在线 获取 于
<https://doi.org/10.1016/j.atmosres.2026.109037>。

数据 可用性

本研究使用的代码可在以下位置获取：<https://github.com/ttakenawa/PostMSM>。由于数据许可限制，该仓库提供了一个合
成/衍生数据集用于演示，可能无法精确重现论文结果。

参考文献

Akiba, T., Sano, S., Yanase, T., Ohta, T., Koyama, M., 2019年。Optuna: 下一代
超参数优化框架。收录于：第25届ACM SIGKDD知识发现与数据挖掘国际会议论文集。第
2623–2631页。 <http://dx.doi.org/10.1145/3292500.3330701>。Bauer, P., Thorpe, A.,
Brunet, G., 2015年。数值天气预报的静默革命。《自然》525, 47–55。
<http://dx.doi.org/10.1038/nature14956>。Bedi, J., Toshniwal, D., 2018年。基于相关
分析的属性选择。收录于：《大数据与云计算进展》。施普林格, 第51–61页。
Chandrashekar, G., Sahin, F., 2014年。特征选择方法综述。《计算机与电气工程》
40, 16–28。 <http://dx.doi.org/10.1016/j.compeleceng.2013.11.024>。Dunn, P.K.,
Smyth, G.K., 2005年。Tweedie指数色散模型密度的级数评估。《统计计算》15, 267–
280。 <http://dx.doi.org/10.1007/s11222-005-4070-y>。Grinsztajn, L., Oyallon, E.,
Varoquaux, G., 2022年。为什么基于树的模型在典型表格数据上仍优于深度学习？《神
经信息处理系统进展》35, 507–520。

Hieta, L., Partio, M., 2025年。短时温度、湿度、风速和阵风预报的业务化机器学习后处理。《气
象应用》32, e70074。 <http://dx.doi.org/10.1002/met.70074>。Iwase, K., Takenawa, T., 2024
年。基于机器学习的山地天气预报插值。《信息处理杂志》32, 873–880。
<http://dx.doi.org/10.2197/ipsjip.32.873>。JMA, 2024年。日本气象厅业务数值天气预报概要。
<https://www.jma.go.jp/jma/jma-eng/jma-center/nwp/outline2024-nwp/index.htm>。（访问日
期：2024年9月22日）。Jørgensen, B., 1997年。《色散模型理论》。Chapman & Hall。Ke, G.,
Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., Liu, T.Y., 2017年。
LightGBM: 一种高效的梯度提升决策树。《神经信息处理系统进展》30。Kingma, D.P., 2014年。
Adam: 一种随机优化方法。arXiv预印本 arXiv:1412.6980。Kudo, A., 2022年。使用基于编码器-解
码器的深度卷积神经网络对网格温度预测进行统计后处理。《日本气象学会杂志第二辑》100, 219–
232。 <http://dx.doi.org/10.2151/jmsj.2022-011>。LightGBM贡献者, 2026年。LightGBM参数。
<https://lightgbm.readthedocs.io/en/latest/Parameters.html>。（访问日期：2026年3月18日）。
Liu, Q., Lou, X., Yan, Z., Qi, Y., Jin, Y., Yu, S., Yang, X., Zhao, D., Xia, J., 2023年。基
于NWP预报的短期站点降水的深度学习后处理。《大气研究》295, 107032。
<http://dx.doi.org/10.1016/j.atmosres.2023.107032>。OPTUNA, 2024年。
Optuna.integration.lightgbm.LightGBMTuner; Optuna 2.0.0文档。
h
t
t
p
s://
o
p
t
u
n
a.
r
e
a
d
t
h
e
docs.io/en/v2.0.0/reference/generated/optuna.integration.lightgb
m.LightGBMTuner.html。（访问日期：2024年12月5日）。Peng, T., Zhi, X., Ji, Y., Ji, L.,
Tian, Y., 2020年。使用机器学习后处理方法对延伸期2米最高气温概率预报的预测技巧。《大气》
11, 823。 <http://dx.doi.org/10.3390/atmos11080823>。RISH, 2024年。欢迎访问RISH网站数据服
务器。 <http://database.rish.kyoto-u.ac.jp/index-e.html>。（访问日期：2024年9月22日）。
Rojas-Campos, A., Wittenbrink, M., Nieters, P., Schaffernicht, E.J., Keller, J.D., Pipa,
G., 2023年。使用深度学习对NWP降水预报进行后处理。《天气与预报》38, 487–497。
<http://dx.doi.org/10.1175/WAF-D-21-0207.1>。Ross, B.C., 2014年。离散和连续数据集之间的互信
息。《PLoS One》9, e87357。 <http://dx.doi.org/10.1371/journal.pone.0087357>。Salazar,
A.A., Che, Y., Zheng, J., Xiao, F., 2022年。多变量神经网络后处理短期轮毅高度风速预报。
《能源科学与工程》10, 2561–2575。 <http://dx.doi.org/10.1002/ese3.928>。Shwartz-Ziv, R.,
Armon, A., 2022年。表格数据：深度学习并非万能。《信息融合》81, 84–90。
<http://dx.doi.org/10.1016/j.inffus.2021.11.011>。Tang, R., Ning, Y., Li, C., Feng, W.,
Chen, Y., Xie, X., 2021年。使用单站单时空域LightGBM方法的温度和风速数值预报订正。《传感
器》22, 193。 <http://dx.doi.org/10.3390/s22010193>。TensorFlow, 2024年。TensorFlow。
<https://www.tensorflow.org/>。（访问日期：2024年12月8日）。Tsipis, E., Banti, K., Louta,
M., Dimokas, N., 2023年。使用机器学习技术提高开放天气预报数据准确性。收录于：2023年第
14届信息、智能、系统与应用国际会议。IISA, IEEE, 第1–8页。
<http://dx.doi.org/10.1109/IISA59645.2023.10345915>。Xu, W., Ning, L., Luo, Y., 2020年。基
于梯度提升决策树算法的数值天气预报后处理风速预报。《大气》11, 738。
<http://dx.doi.org/10.3390/atmos11070738>。Yoshikane, T., Yoshimura, K., 2022年。通过识别
与天气条件对应的中尺度降水系统对降水进行偏差校正方法。《PLoS Water》1, e0000016。
<http://dx.doi.org/10.1371/journal.pwat.0000016>。Zhang, Y., Ye, A., 2021年。降水预报后处理
的机器学习：多模型比较与实验研究。《水文气象杂志》22, 3065–3085。
<http://dx.doi.org/10.1175/JHM-D-21-0096.1>。